

机器学习导论 习题四

学号, 姓名, 邮箱

2024 年 6 月 5 日

作业提交注意事项

1. 作业所需的 LaTeX 及 Python 环境配置要求请参考: [Link];

2. 请在 LaTeX 模板中第一页填写个人的学号、姓名、邮箱;

3. 本次作业需提交的文件为:

(a) 作答后的 LaTeX 代码 — `HW4.tex`;

(b) 由 (a) 编译得到的 PDF 文件 — `HW4.pdf`;

(c) 题目 2.(2) 的求解代码文件 — `svm_qp_dual.py`

(d) 题目 3 的求解代码文件 — `svm_kernel_solution.py`

其他文件 (如其他代码、图片等) 无需提交. 请将以上文件**打包为** 学号_姓名.zip (例如 221300001_张三.zip) 后提交;

3. 若多次提交作业, 则在命名 .zip 文件时加上版本号, 例如 221300001_张三_v1.zip” (批改时以版本号最高的文件为准);

4. 本次作业提交截止时间为 **5 月 28 日 23:59:59**. 未按照要求提交作业, 提交作业格式不正确, **作业命名不规范**, 将会被扣除部分作业分数; 除特殊原因 (如因病缓交, 需出示医院假条) 逾期未交作业, 本次作业记 0 分; **如发现抄袭, 抄袭和被抄袭双方成绩全部取消**;

5. 学习过程中, 允许参考 ChatGPT 等生成式语言模型的生成结果, 但必须在可信的信息源处核实信息的真实性; **不允许直接使用模型的生成结果作为作业的回答内容**, 否则将视为作业非本人完成并取消成绩;

6. 本次作业提交地址为 [Link], 请大家预留时间提前上交, 以防在临近截止日期时, 因网络等原因无法按时提交作业.

1 [35pts] Soft Margin

考虑软间隔 SVM 问题, 其原问题形式如下:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + C \sum_{i=1}^m \xi_i^p \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i \\ & \xi_i \geq 0, i \in [m]. \end{aligned} \quad (1.1)$$

其中, 松弛变量 $\xi = \{\xi_i\}_{i=1}^m, \xi_i > 0$ 表示样本 \mathbf{x}_i 对应的间隔约束不满足的程度, 在优化问题中加入惩罚 $C \sum_{i=1}^m \xi_i^p, C > 0, p \geq 1$ 使得不满足约束的程度尽量小 ($\xi_i \rightarrow 0$). 课本式 (6.35) 即为 $p = 1$ 时对应的情况, 此时, 所有违反约束的样本都会受到相同比例的惩罚, 而不考虑它们违反约束的程度. 这可能导致模型对较大偏差的样本不够敏感, 不足以强调更严重的违规情况. 下面将考虑一些该问题的变式:

- (1) [2+7pts] 我们首先考虑 $p = 2$ 的情况, 它对于违反约束程度较大的样本提供了更大的惩罚.
 - (a) 如课本式 (6.34)-(6.35) 所述, $p = 1$ 的情况对应了 hinge 损失 $\ell_{\text{hinge}} : x \rightarrow \max(0, 1 - x)$. 请直接写出 $p = 2$ 的情况下对应的损失函数.
 - (b) 请推导 $p = 2$ 情况下软间隔 SVM 的对偶问题.
- (2) [14pts] $p = 1$ 的情况下, 相当于对向量 ξ 使用 L_1 范数惩罚: $\|\xi\|_1 = \sum_i |\xi_i|$. 现在, 我们考虑使用 L_∞ 范数惩罚: $\|\xi\|_\infty = \max_i \xi_i$, 这会使得模型着重控制最大的违背约束的程度, 从而促使模型在最坏情况下的表现尽可能好. 请推导使用 L_∞ 范数惩罚的原问题和对偶问题.
- (3) [4+8pts] 在(1.1)中, 正例和负例在目标函数中分类错误的“惩罚”是相同的. 然而在实际场景中, 很多时候正例和负例错分的“惩罚”代价是不同的 (参考教材 2.3.4 节). 比如考虑癌症诊断问题, 将一个确实患有癌症的人误分类为健康人, 以及将健康人误分类为患有癌症, 产生的错误影响以及代价不应该认为是等同的. 所以我们考虑对负例违反间隔约束的样本施加 $k > 0$ 倍于正例中违反间隔约束的样本的“惩罚”.
 - (a) 令(1.1)中 $p = 1$, 并令所有正例样本的集合为 D_+ , 负例样本的集合为 D_- . 请给出相应的 SVM 优化问题.
 - (b) 请给出相应的对偶问题.

Solution. 解答如下:

- (1) (a) $\ell : x \rightarrow \max(0, 1 - x)^2$.
- (b) 对于 $p = 2$ 的情况, 拉格朗日函数为:

$$\begin{aligned} L(\mathbf{w}, b, \alpha, \xi) = & \frac{1}{2} \mathbf{w} \cdot \mathbf{w} + C \sum_{i=1}^m \xi_i^2 \\ & - \sum_{i=1}^m \alpha_i [y_i (\mathbf{w} \cdot \mathbf{x}_i + b) - 1 + \xi_i] - \sum_{i=1}^m \mu_i \xi_i. \end{aligned}$$

相比于 $p = 1$ 的情况, 其完整 KKT 条件仅为将 $C = \alpha_i + \mu_i$ 替换为 $2C\xi_i = \alpha_i + \mu_i$, 因此对偶问题为:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i,j=1}^m y_i y_j \alpha_i \alpha_j \mathbf{x}_i^\top \mathbf{x}_j - \frac{1}{4C} \sum_{i=1}^m \alpha_i^2 \\ \text{s.t.} \quad & \alpha_i \geq 0, \forall i \in [m] \\ & \sum_{i=1}^m \alpha_i y_i = 0, \forall i \in [m]. \end{aligned}$$

(2) 当使用 ℓ_∞ 范数惩罚时, 该问题的原问题可等价:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C\xi \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi, \quad i \in [m]. \\ & \xi \geq 0 \end{aligned}$$

拉格朗日函数为:

$$L(\mathbf{w}, b, \alpha, \xi, \mu) = \frac{1}{2} \mathbf{w}^\top \mathbf{w} + C\xi - \sum_{i=1}^m \alpha_i [y_i (\mathbf{w}^\top \mathbf{x}_i + b) - 1 + \xi] - \mu\xi,$$

在该种情况下, 其完整 KKT 条件即将 $p = 1$ 时的 $C = \alpha_i + \mu_i$ 替换为 $C = \sum_i \alpha_i + \mu$, 该等式可在 $\mu \geq 0, \alpha_i \geq 0$ 时替换为不等式约束 $\|\alpha\|_1 \leq C$, 因此对偶问题为:

$$\begin{aligned} \max_{\alpha} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s.t.} \quad & \alpha_i \geq 0, \quad \forall i \in [m] \\ & \|\alpha\|_1 \leq C, \quad \forall i \in [m] \\ & \sum_{i=1}^m \alpha_i y_i = 0, \quad \forall i \in [m]. \end{aligned}$$

(3) (a) 优化目标为:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi_i} \quad & \frac{1}{2} \|\mathbf{w}\|^2 + C \left(\sum_{i \in D_+} \xi_i + k \sum_{i \in D_-} \xi_i \right) \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i \in [m] \\ & \xi_i \geq 0, \quad i \in [m]. \end{aligned}$$

(b) 令 $\alpha = (\alpha_1; \dots; \alpha_m) \in \mathbb{R}_+^m$, $\mu = (\mu_1; \dots; \mu_m) \in \mathbb{R}_+^m$ 表示拉格朗日乘子, 则

$$\begin{aligned} L(\mathbf{w}, b, \xi, \alpha, \mu) = & \frac{1}{2} \|\mathbf{w}\|^2 + C \left(\sum_{i \in D_+} \xi_i + k \sum_{i \in D_-} \xi_i \right) \\ & + \sum_{i=1}^m \alpha_i (1 - \xi_i - y_i (\mathbf{w}^\top \mathbf{x}_i + b)) - \sum_{i=1}^m \mu_i \xi_i, \end{aligned}$$

令 $\nabla_{\mathbf{w}} L = \nabla_b L = \nabla_{\xi_i} L = 0$, 则有

$$\begin{cases} \mathbf{w} = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \\ 0 = \sum_{i=1}^m \alpha_i y_i \\ C = (\alpha_i + \mu_i) \cdot \left(\frac{1}{k} |D_+| + |D_-|\right) \end{cases}$$

其中, $|D_+|$ 和 $|D_-|$ 分别表示正负类样本的数量. 于是得到对偶问题如下:

$$\begin{aligned} \max_{\boldsymbol{\alpha}} \quad & \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j \\ \text{s.t.} \quad & \sum_{i=1}^m y_i \alpha_i = 0 \\ & 0 \leq \alpha_i \leq C \cdot (k|D_+| + |D_-|) \end{aligned}$$

2 [20pts] Primal and Dual Problem

给定一个包含 m 个样本的数据集 $D = \{(\mathbf{x}_i, y_i)\}_{i=1}^m$, 其中每个样本的特征维度为 d , 即 $\mathbf{x}_i \in \mathbb{R}^d$. 软间隔 SVM 的原问题和对偶问题可以表示为:

原问题:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \mathbf{w}^\top \mathbf{w} + C \sum_{i=1}^n \xi_i \\ \text{s.t.} \quad & y_i (\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \forall i \in [m] \\ & \xi_i \geq 0, \forall i \in [m] \end{aligned}$$

对偶问题:

$$\begin{aligned} \min_{\boldsymbol{\alpha}} \quad & \frac{1}{2} \boldsymbol{\alpha}^\top \mathbf{Q} \boldsymbol{\alpha} - \mathbf{1}_m^\top \boldsymbol{\alpha} \\ \text{s.t.} \quad & \mathbf{y}^\top \boldsymbol{\alpha} = 0 \\ & 0 \leq \alpha_i \leq C, \forall i \in [m] \end{aligned}$$

其中, 对于任意 $i, j \in [m]$ 有 $\mathbf{Q}_{ij} \equiv y_i y_j \mathbf{x}_i^\top \mathbf{x}_j$.

上述的原问题和对偶问题都是二次规划 (Quadratic Programming) 问题, 都可以使用相关软件包求解. 本题目中我们将通过实践来学习凸优化软件包的使用, 并以软间隔 SVM 为例了解原问题、对偶问题在优化方面的特性.

- (1) [2pts] 请直接写出原问题和对偶问题的参数量 (注意参数只包含分类器所保存的参数, 不包含中间变量).
- (2) [10pts] 请参考 `lab2/svm_qp.py` 中对于原问题的求解代码, 编写对偶问题的求解代码. (这里使用了 CVXPY 求解 QP 问题.) 请将代码提交至下方的解答处.
- (3) [8pts] 设特征维度和样例数量的比值 $r = \frac{d}{m}$, 请绘制原问题和对偶问题的求解速度随着这个比值变化的曲线图. 并简述: 何时适合求解原问题, 何时适合求解对偶问题?

Solution. 解答如下:

- (1) 原问题需要求解 \mathbf{w}, b , 因此参数量为 $d + 1$; 对偶问题需要求解 $\boldsymbol{\alpha}$, 因此参数量为 m .
- (2) 对偶问题的求解代码为:

```
1 import cvxpy as cp
2
3 def solve_dual(X, y, C):
4     m = X.shape[0]
5     alpha = cp.Variable(m)
6     y_ = y.reshape(-1, 1)
7     Q = y_ * y_.T * (X @ X.T)
8     loss = 0.5 * cp.quad_form(alpha, Q) - cp.sum(alpha)
9     prob = cp.Problem(cp.Minimize(loss),
10                        [cp.sum(cp.multiply(y, alpha)) == 0,
11                         alpha >= 0,
12                         alpha <= C])
13     prob.solve()
14     return alpha
```

- (3) 曲线图为: (略)

随着 r 的增加, 原问题的求解时间逐渐高于对偶问题的求解时间, 可以大致得出结论, 若样本数量大于维度, 适合求解原问题, 而当维度高于样本数量时, 适合求解对偶问题.

3 [15pts] Kernel Function in Practice

lab3/svm_kernel.py 中构造了异或 (XOR) 问题, 如图 1 所示. 该问题是线性不可分的.




图 1: 异或 (XOR) 问题

本题中我们将通过实验了解核函数的选择对于 SVM 解决非线性问题的影响. 请使用 sklearn 包中的 SVC 分类器完成下述实验:

- (1) [6pts] 请分别训练线性核 SVC 分类器和核 (RBF 核) SVC 分类器, 并绘制出各自的决策边界.
- (2) [6pts] sklearn 还允许自定义核函数, 参考 lab3/svm_kernel_custom.py 的用法, 编写核函数 $\kappa(\mathbf{x}, \mathbf{x}') = \frac{1}{1 + \|\mathbf{x} - \mathbf{x}'\|_2^2}$, 训练该核函数的 SVC 分类器, 并绘制出决策边界.

具体的实验要求可以参考 lab3/svm_kernel.py 的 main 部分. 请将 lab3/svm_kernel_solution.py 中的代码和三个核函数分别对应的决策边界图提交至下方的解答处.

最后, 请直接回答 [3pts]: 三个核函数, 各自能够解决异或 (XOR) 分类问题吗?


Solution. 解答如下:

求解代码为:


```
1 from sklearn import svm
2 import numpy as np
3
4 def svm_kernel_linear(X, Y):
5     clf = svm.SVC(kernel='linear')
6     clf.fit(X, Y)
7     return clf
8
9 def svm_kernel_rbf(X, Y):
10    clf = svm.SVC(kernel='rbf')
11    clf.fit(X, Y)
12    return clf
13
14 def custom_kernel(X, Y):
15    return 1 / (1 + np.sum((np.expand_dims(X, 1) - np.expand_dims(Y, 0)) ** 2, -1))
16
17 def svm_kernel_custom(X, Y):
```

```
18     clf = svm.SVC(kernel=custom_kernel)
19     clf.fit(X, Y)
20     return clf
```


决策边界为：



(a) clf_linear



(b) clf_rbf



(c) clf_custom

线性核函数无法解决, rbf 核函数和自定义核函数可以.

4 [30pts] Maximum Likelihood Estimation

给定由 m 个样本组成的训练集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$, 其中 $\mathbf{x}_i \in \mathbb{R}^d$ 是第 i 个示例, $y_i \in \mathbb{R}$ 是对应的实值标记. 令 $\mathbf{X} \in \mathbb{R}^{m \times d}$ 表示整个训练集中所有样本特征构成的矩阵, 并令 $\mathbf{y} \in \mathbb{R}^m$ 表示训练集中所有样本标记构成的向量. 线性回归的目标是寻找一个参数向量 $\mathbf{w} \in \mathbb{R}^d$, 使得在训练集上模型预测的结果和真实标记之间的差距最小. 对于一个样本 \mathbf{x} , 线性回归给出的预测为 $\hat{y} = \mathbf{w}^\top \mathbf{x}$,¹ 它与真实标记 y 之间的差距可以用平方损失 $(\hat{y} - y)^2$ 来描述. 因此, 在整个训练集上最小化损失函数的过程可以写作如下的优化问题:

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2 \quad (4.1)$$

- (1) [8pts] 考虑这样一种概率观点: 样本 \mathbf{x} 的标记 y 是从一个高斯分布 $\mathcal{N}(\mathbf{w}^\top \mathbf{x}, \sigma^2)$ 中采样得到的. 这个高斯分布的均值由样本特征 \mathbf{x} 和模型参数 \mathbf{w} 共同决定, 而方差是一个额外的参数 σ^2 . 基于这种概率观点, 我们可以基于观测数据对高斯分布中的参数 \mathbf{w} 做极大似然估计. 请证明: \mathbf{w} 的极大似然估计结果 \mathbf{w}_{MLE} 与式 (4.1) 中的 \mathbf{w}^* 相等;
- (2) [9pts] 极大似然估计容易过拟合, 一种常见的解决办法是采用最大后验估计: 沿着上一小问的思路, 现在我们在概率建模下对参数 \mathbf{w} 做最大后验估计. 为此, 引入参数 \mathbf{w} 上的先验 $p(\mathbf{w}) = \mathcal{N}(\mathbf{0}, \lambda \mathbf{I})$. 其中, 均值 $\mathbf{0}$ 是 d 维的全 0 向量, \mathbf{I} 是 d 维单位矩阵, $\lambda > 0$ 是一个控制方差的超参数. 现在, 请推导对 \mathbf{w} 做最大后验估计的目标函数, 并讨论一下该结果与“带有 L_2 范数正则项的线性回归”之间的关系;
- (3) [9pts] 沿着上一小问的思路, 我们尝试给参数 \mathbf{w} 施加一个拉普拉斯先验. 简便起见, 我们假设参数 \mathbf{w} 的 d 个维度之间是独立的, 且每一维都服从 0 均值的一元拉普拉斯分布, 即:

$$p(\mathbf{w}) = \prod_{j=1}^d p(w_j), \quad (4.2)$$

$$p(w_j) = \text{Lap}(w_j | 0, \lambda), \quad j = 1, 2, \dots, d.$$

请推导对 \mathbf{w} 做最大后验估计的目标函数, 并讨论一下该结果与“带有 L_1 范数正则项的线性回归”之间的关系;

Note: 由参数 μ, λ 确定的一元拉普拉斯分布的概率密度函数为:

$$\text{Lap}(w | \mu, \lambda) = \frac{1}{2\lambda} \exp\left(-\frac{|w - \mu|}{\lambda}\right). \quad (4.3)$$

- (4) [4pts] 基于 (2) 和 (3) 的结果, 从概率角度讨论为什么 L_1 范数可以使模型参数变得稀疏.

Solution. 解答如下:

- (1) 由于 $y \sim \mathcal{N}(\mathbf{w}^\top \mathbf{x}, \sigma^2)$, 所以在给定一个样本特征 \mathbf{x} 时, 其观测标记 y 的似然为:

$$p(y | \mathbf{x}, \mathbf{w}, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - \mathbf{w}^\top \mathbf{x})^2}{2\sigma^2}\right). \quad (4.4)$$

¹ 本题不考虑偏移 b , 可参考教材第 3 章将偏移 b 吸收进 \mathbf{w} .

考虑整个训练集中所有样本, 可以得到 \mathbf{y} 的似然:

$$p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^m \prod_{i=1}^m \exp \left(-\frac{(y_i - \mathbf{w}^\top \mathbf{x}_i)^2}{2\sigma^2} \right). \quad (4.5)$$

对上式取对数, 得到如下的目标函数:

$$f_{\text{MLE}}(\mathbf{w}) = -\frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 - m \log \sigma - \frac{m}{2} \log(2\pi). \quad (4.6)$$

将该目标函数中与 \mathbf{w} 无关的项忽略, 并省去系数 $-\frac{1}{2\sigma^2}$ 同时将求最大值改为求最小值, 得到的结果为:

$$g_{\text{MLE}}(\mathbf{w}) = \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|_2^2. \quad (4.7)$$

这个最小化的目标与式 (4.1) 中的目标函数完全相同. 因此, $\mathbf{w}_{\text{MLE}} = \mathbf{w}^*$.

(2) 参数 \mathbf{w} 的先验为:

$$\begin{aligned} p(\mathbf{w} | \lambda) &= \frac{1}{(2\pi)^{\frac{d}{2}}} \frac{1}{|\lambda \mathbf{I}|^{\frac{1}{2}}} \exp \left(-\frac{1}{2} (\mathbf{w} - \mathbf{0})^\top (\lambda \mathbf{I})^{-1} (\mathbf{w} - \mathbf{0}) \right) \\ &= \left(\frac{1}{2\pi\lambda} \right)^{\frac{d}{2}} \exp \left(-\frac{1}{2\lambda} \mathbf{w}^\top \mathbf{w} \right), \end{aligned} \quad (4.8)$$

而训练集中 \mathbf{y} 的似然为:

$$p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \sigma^2) = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^m \prod_{i=1}^m \exp \left(-\frac{(y_i - \mathbf{w}^\top \mathbf{x}_i)^2}{2\sigma^2} \right), \quad (4.9)$$

所以参数 \mathbf{w} 的后验为:

$$\begin{aligned} p(\mathbf{w} | \mathbf{y}, \mathbf{X}, \sigma^2, \lambda) &\propto p(\mathbf{w} | \lambda) p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \sigma^2) \\ &= \left(\frac{1}{2\pi\lambda} \right)^{\frac{d}{2}} \exp \left(-\frac{1}{2\lambda} \mathbf{w}^\top \mathbf{w} \right) \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^m \prod_{i=1}^m \exp \left(-\frac{(y_i - \mathbf{w}^\top \mathbf{x}_i)^2}{2\sigma^2} \right). \end{aligned} \quad (4.10)$$

对上式取对数, 可得目标函数如下:

$$f_{\text{MAP-Gaussian}}(\mathbf{w}) = -\frac{1}{2\sigma^2} \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 - \frac{1}{2\lambda} \|\mathbf{w}\|_2^2 - \frac{d+m}{2} \log(2\pi) - m \log \sigma - \frac{d}{2} \log \lambda. \quad (4.11)$$

忽略掉常数项, 并除以系数 $-\frac{1}{2\sigma^2}$, 同时将最大化问题改为最小化, 得到的结果为:

$$g_{\text{MAP-Gaussian}}(\mathbf{w}) = \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \frac{\sigma^2}{\lambda} \|\mathbf{w}\|_2^2. \quad (4.12)$$

式 (4.12) 在形式上与 “带有 L_2 范数正则项的线性回归” 完全一致.

(3) 与上一小问类似, 参数 \mathbf{w} 的后验正比于其先验与数据似然的乘积, 故有:

$$\begin{aligned} p(\mathbf{w} | \mathbf{y}, \mathbf{X}, \sigma^2, \lambda) &\propto p(\mathbf{w} | \lambda) p(\mathbf{y} | \mathbf{X}, \mathbf{w}, \sigma^2) \\ &= \left(\frac{1}{2\lambda} \right)^d \prod_{j=1}^d \exp \left(-\frac{|w_j|}{\lambda} \right) \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^m \prod_{i=1}^m \exp \left(-\frac{(y_i - \mathbf{w}^\top \mathbf{x}_i)^2}{2\sigma^2} \right). \end{aligned} \quad (4.13)$$

对上式取对数, 可得目标函数如下:

$$f_{\text{MAP-Laplacian}} = -\frac{1}{2\sigma^2}(y_i - \mathbf{w}^\top \mathbf{x}_i)^2 - \frac{1}{\lambda} \|\mathbf{w}\|_1 - d \log(2\lambda) - m \log \sigma - \frac{m}{2} \log(2\pi) . \quad (4.14)$$

忽略掉常数项, 并除以系数 $-\frac{1}{2\sigma^2}$, 同时将最大化问题改为最小化, 得到的结果为:

$$g_{\text{MAP-Laplacian}} = \sum_{i=1}^m (y_i - \mathbf{w}^\top \mathbf{x}_i)^2 + \frac{2\sigma^2}{\lambda} \|\mathbf{w}\|_1 . \quad (4.15)$$

式 (4.15) 在形式上与 “带有 L_1 范数正则项的线性回归” 完全一致.

- (4) 拉普拉斯先验在 0 处有更高的概率密度. 所以, 拉普拉斯先验更容易使得参数 \mathbf{w} 中各维的取值等于 0.

Acknowledgments

允许与其他同样未完成作业的同学讨论作业的内容, 但需在此注明并加以致谢; 如在作业过程中, 参考了互联网上的资料 (包括生成式模型的结果), 且对完成作业有帮助的, 亦需注明并致谢.